

10 - Respuesta binaria

- 1 Predicción de una respuesta binaria
- 2 Modelo estadístico para predicción binaria
- 3 El modelo de regresión logística
- 4 Condición de no existencia de solución

Descripción del modelo

Se plantea el modelo

$$y_i = p_i + \varepsilon_i, \quad i = 1, \dots, n,$$

donde

$$p_i = F(\mathbf{x}_i \cdot \boldsymbol{\beta}).$$

F es la función logística. Escribimos \mathbf{x}_i como una fila $1 \times m$. Frecuentemente $x_{i1} = 1$.

Así, escribiendo $\boldsymbol{\beta}$ como una columna $m \times 1$, su primera componente es el término constante.

Estimación de parámetros: Máxima Verosimilitud

La verosimilitud para la observación i -ésima es:

$$\mathcal{L}_i(\boldsymbol{\beta}) = \begin{cases} p_i, & \text{si } y_i = 1, \\ 1 - p_i, & \text{si } y_i = 0. \end{cases}$$

que puede abreviarse, según es usual, como

$$\mathcal{L}_i(\boldsymbol{\beta}) = p_i^{y_i} (1 - p_i)^{(1-y_i)}.$$

La verosimilitud $\mathcal{L}(\boldsymbol{\beta})$ es el producto de estos n factores.

Ecuaciones de verosimilitud

El logaritmo $\ell \equiv \ell(\boldsymbol{\beta}) = \log \mathcal{L}(\boldsymbol{\beta})$ es:

$$\ell = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

Teniendo en cuenta que $p_i = F(\sum_{k=1}^m x_{ik} \beta_k)$,

$$\frac{\partial p_i}{\partial \beta_j} = p_i (1 - p_i) x_{ij},$$

las ecuaciones de verosimilitud son:

$$\frac{\partial \ell}{\partial \beta_j} = \sum_{i=1}^n (y_i - p_i) x_{ij} = 0, \quad j = 1, \dots, m.$$

Ecuaciones de verosimilitud

En notación matricial,

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \mathbf{V} \cdot \mathbf{X},$$

donde

$$\mathbf{V} = \text{diag}\{\mathbf{p}(1 - \mathbf{p})\}$$

es la matriz diagonal $n \times n$ con elementos $p_i(1 - p_i)$ en su diagonal principal.

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \mathbf{X}' \cdot (\mathbf{y} - \mathbf{p}).$$

Segunda derivada

La segunda derivada de ℓ es:

$$\frac{\partial^2 \ell}{\partial \beta_j \partial \beta_k} = - \sum_{i=1}^n p_i (1 - p_i) x_{ik} x_{ij}$$

En notación matricial:

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} = -\mathbf{X}' \cdot \mathbf{V} \cdot \mathbf{X}.$$

Matriz de Información de Fisher

Las derivadas segundas no dependen de las observaciones y_i , por tanto, coinciden con sus esperanzas, las componentes g_{jk} de la matriz de información de Fisher.

Así, la matriz de información de Fisher es:

$$\mathbf{G} = \mathbf{X}' \cdot \mathbf{V} \cdot \mathbf{X}.$$

Cálculo de solución: IWLS (o IRLS)

Aproximaciones sucesivas.

A partir de un $\beta(0)$ se calcula una segunda aproximación $\beta(1)$, y así sucesivamente.

Aplicando el método de Newton-Raphson o su variante, el método de *Fisher scoring*, que en este caso coinciden, pues la segunda derivada no depende de las observaciones, se obtienen aproximaciones sucesivas $\beta(r)$, $r \geq 0$.

Cálculo de solución: IWLS (o IRLS)

En general, dado un $\boldsymbol{\beta} \equiv \boldsymbol{\beta}(r)$,

$$\boldsymbol{p}(r) = F(\boldsymbol{X} \cdot \boldsymbol{\beta}),$$

$$\boldsymbol{V}(r) = \text{diag}\{\boldsymbol{p}(r)(1 - \boldsymbol{p}(r))\},$$

$$\boldsymbol{G}(r) = \boldsymbol{X}' \cdot \boldsymbol{V}(r) \cdot \boldsymbol{X},$$

$$\boldsymbol{\delta}(r) = \boldsymbol{G}^{-1} \cdot \boldsymbol{X}' \cdot (\boldsymbol{y} - \boldsymbol{p}(r)),$$

$$\boldsymbol{\beta}(r+1) = \boldsymbol{\beta}(r) + \boldsymbol{\delta}(r).$$


10 - Respuesta binaria

- 1 Predicción de una respuesta binaria
- 2 Modelo estadístico para predicción binaria
- 3 El modelo de regresión logística
- 4 Condición de no existencia de solución

Enunciado del teorema. Versión geométrica

Si la nube de puntos \mathbf{x}_i correspondientes a los $y_i = 1$ queda completamente separada de la nube de puntos \mathbf{x}_i correspondientes a los $y_i = 0$, entonces no tiene solución la ecuación de verosimilitud.

Ilustración



A modo de precaución

Es importante tener en cuenta este problema cuando se calcula con datos reales.

Los algoritmos numéricos, en presencia de esta situación, producen resultados impredecibles, pero siempre indeseables.